

Projekt:

Visuelle Inspektion und Defekterkennung von Winkelschleifer-Komponenten für die Kreislauffabrik

Projektstart:	08.05.2026
Abgabe (Folien + Code):	31.07.2026, 23:59 Uhr via ILIAS
Präsentation:	07.08.2026

1 Hintergrund

Im Kontext der **Kreislauffabrik (SFB 1574)** am KIT werden gebrauchte Produkte systematisch zurückgeführt, zerlegt und deren Komponenten für das Remanufacturing aufbereitet. Ein zentraler Schritt in diesem Prozess ist die **visuelle Inspektion**: Um fundierte Entscheidungen über die Wiederverwendbarkeit von Bauteilen treffen zu können, müssen zunächst die vorliegenden Komponenten **identifiziert** und anschließend auf **domänenspezifische Defekte** untersucht werden.

Als Anwendungsbeispiel dient in diesem Projekt ein handelsüblicher Winkelschleifer. Die Herausforderung besteht darin, dass im Remanufacturing-Umfeld nur wenige gelabelte Bilddaten zur Verfügung stehen, insbesondere für Defekte. Dies erfordert durchdachte Strategien zur Datenzusammensetzung, Netzwerkauswahl und zum Umgang mit datenarmen Szenarien.

2 Bereitgestellte Datensätze

Für das Projekt werden drei Datensätze bereitgestellt, die aufeinander aufbauen:

2.1 Datensatz A – Synthetische Daten

Synthetisch generierte Bilder von Winkelschleifer-Komponenten. Da im Remanufacturing nur wenige reale Daten vorliegen, dienen diese als **Grundlage für das initiale Training**. Der Datensatz enthält Klassen-Labels und Segmentierungsmasken, jedoch nicht von Defekten, lediglich von Komponenten.

2.2 Datensatz B – Reale Aufnahmen (Objekte & Assemblies)

Reale Aufnahmen von ganzen Winkelschleifern sowie einzelnen Baugruppen (Assemblies) und Komponenten. Dieser Datensatz dient der Evaluation und dem Fine-Tuning auf realen Domänendaten.

2.3 Datensatz C – Nahaufnahmen mit Defekten

Detailaufnahmen einzelner Bauteile, auf denen **Defekte sichtbar** sind (z. B. Kratzer, Abplatzungen, Verschleißspuren, Verformungen). Die Anzahl der Fehlerbilder ist **gering** und spiegelt damit die reale Datenlage wider und erfordert geeignete Strategien (z. B. Data Augmentation, Few-Shot Learning, Transfer Learning, Anomalieerkennung).

3 Aufgabenstellung

Das Projekt folgt dem **CRISP-DM-Vorgehensmodell** und gliedert sich in die folgenden Arbeitspakete:

3.1 AP 1 – Data Understanding & Preparation

- Explorative Analyse aller drei Datensätze (Klassenverteilungen, Bildqualität, Annotation-Formate).
- Aufbereitung der Daten in geeignete Train-/Validation-/Test-Splits. Die vorgegebene Ordnerstruktur darf und soll bei Bedarf angepasst werden.
- Dokumentation der Datenqualität und identifizierter Probleme.

3.2 AP 2 – Komponentenklassifikation & Instanzsegmentierung

- Entwicklung einer Strategie aus Netzwerkarchitektur und Datenzusammensetzung (synthetisch vs. real) für eine möglichst gute Klassifikation der Winkelschleifer-Komponenten.
- Systematische Untersuchung, wie sich der Mix aus synthetischen (Datensatz A) und realen Daten (Datensatz B) auf die Klassifikationsgüte auswirkt.
- Auswahl und Training eines geeigneten Netzwerks für die instanzspezifische Segmentierung (Instance Segmentation).
- Evaluation anhand gängiger Metriken (Precision, Recall, mAP, IoU).

3.3 AP 3 – Defekterkennung auf Nahaufnahmen

- Entwicklung eines Ansatzes zur Detektion von Defekten auf den Nahaufnahmen (Datensatz C).
- **Zentrale Herausforderung:** Es liegen nur wenige Bilder mit Defekten vor. Geeignete Strategien sind zu evaluieren und zu begründen (z. B. Data Augmentation, Few-Shot Learning, Transfer Learning, Anomalieerkennung, synthetische Defektgenerierung).
- Dokumentation und Vergleich der gewählten Ansätze.

3.4 AP 4 – Deployment auf Edge-Hardware

Im finalen Schritt soll die entwickelte Lösung auf einer **realen Inspektionsstation** deployed werden. Folgende Randbedingungen sind zu beachten:

- Die Zielhardware ist ein **NVIDIA Jetson Orin Nano** mit 8 GB Shared RAM.
- Netzwerke müssen entsprechend dimensioniert und ggf. optimiert werden (z. B. TensorRT, Quantisierung, Pruning).
- **Zero-Shot-Ansätze mit VLMs** (z. B. GPT-4V, Claude Vision) dürfen untersucht werden. Gemäß CRISP-DM müssen dabei jedoch die **Kosten** (API-Nutzung) und **Inferenzzeiten** systematisch erfasst und mit On-Device-Lösungen verglichen werden.

4 Bewertungskriterien

Die Bewertung erfolgt anhand folgender Kriterien:

Kriterium	Beschreibung
Methodisches Vorgehen	Strukturiertes Vorgehen nach CRISP-DM, nachvollziehbare Entscheidungen, systematische Experimente
Wissenschaftliche Arbeitsweise	Korrekte Anwendung von Metriken, statistische Absicherung, Literaturrecherche, Reproduzierbarkeit
Ergebnisqualität	Klassifikations-/Segmentierungs-/Detektionsgüte, sinnvolle Modellwahl, Deployment-Tauglichkeit
Dokumentation	Vollständigkeit, Klarheit, nachvollziehbare Darstellung der Ergebnisse und Erkenntnisse
Präsentation	Verständliche Darstellung, kritische Diskussion, Beantwortung von Rückfragen

5 Abgabeleistungen

Folgende Artefakte sind fristgerecht über ILIAS einzureichen:

1. **Präsentationsfolien:** Darstellung des Vorgehens, der Experimente und Ergebnisse.
2. **Quellcode:** Vollständiger, lauffähiger Code (Jupyter Notebooks und/oder Python-Skripte) inkl. Anweisungen zur Reproduktion.
3. **Dokumentation:** Beschreibung der Methodik, Datenvorbereitung, Experimente, Ergebnisse (Metriken, Konfusionsmatrizen, qualitative Beispiele) sowie Diskussion und Ausblick.

6 Hinweise zur Umsetzung

Für die praktische Umsetzung empfehlen wir folgende Werkzeuge und Bibliotheken:

Empfohlene Frameworks

- **PyTorch / torchvision** – für Training und Modellentwicklung
- **Ultralytics (YOLOv11/v26)** – für Detection und Segmentierung
- **SAM2** - Zero-Shot Segmentierung
- **Detectron2 / MMDetection** – für Instance Segmentation
- **OpenCV, Albumentations** – für Bildverarbeitung und Augmentation
- **TensorRT / ONNX Runtime** – für Deployment-Optimierung
- **Weights & Biases / MLflow** – für Experiment-Tracking (optional)

Compute-Ressourcen

Für das Training können **Google Colab** (kostenlose GPU) oder lokale GPUs genutzt werden. Auch temporären Zugang zum NVIDIA DGX Cluster des wbks mit Zugang zu einer Tesla V100 mit 32GB Vram kann zur Verfügung gestellt werden. Für das Deployment steht ein NVIDIA Jetson Orin Nano am Institut zur Verfügung.

Bei Fragen zum Projekt oder zu den Datensätzen wendet euch bitte an dominik.koch@kit.edu und edwin.blum@kit.edu